

Quote e limiti del servizio

Questo contenuto si applica a:  v4.0 (GA) | Versioni precedenti:  v3.1 (GA)  v3.0 (GA)

Questo articolo contiene sia un riferimento rapido che una descrizione dettagliata di Azure Document Intelligence in Foundry Tools Quotas and Limits for all [pricing tiers](#) (Quote e limiti degli strumenti di Foundry per tutti i piani tariffari). Include anche alcune procedure consigliate per evitare la limitazione delle richieste.

Utilizzo del modello

 Espandi la tabella

Tipi di documento supportati	Read	Layout	Modelli predefiniti	Modelli personalizzati	Funzionalità dei componenti aggiuntivi
PDF	✓	✓	✓	✓	✓
Immagini: <code>JPEG/JPG</code> , <code>PNG</code> , <code>BMP</code> , <code>TIFF</code> , <code>HEIF</code>	✓	✓	✓	✓	✓
Microsoft Office: <code>DOCX</code> , <code>PPTX</code> , <code>XLS</code>	✓	✓	✗	✗	✗

✓ = supportato ✗ = non supportato

Per Document Intelligence v4.0 `2024-11-30` (GA) supporta le funzionalità di pagina e riga con le restrizioni seguenti:

- Angolo, larghezza/altezza e unità non sono supportati.
- Per ogni oggetto rilevato, i poligoni di delimitazione o le aree di delimitazione non sono supportati.
- L'oggetto `lines` non è supportato.

- ✓ [SDK di Informazioni sui documenti](#)
- ✓ [API REST di Informazioni sui documenti](#)
- ✓ [Studio di Informazioni sui documenti v3.0](#)

 Espandi la tabella

Quota	Gratuito (F0) ¹	Standard (S0)
Analizzare il limite di transazioni al secondo	1	15 (valore predefinito)
Adjustable	No	Sì ²
Limite di operazioni get al secondo	1	50 (valore predefinito)
Adjustable	No	Sì ²
Limite di operazioni di gestione dei modelli al secondo	1	5 (valore predefinito)
Adjustable	No	Sì ²
Limite di operazioni di elenco al secondo	1	10 (valore predefinito)
Adjustable	No	Sì ²
Dimensioni massime del documento	4 MB	500 MB
Adjustable	No	No
Numero massimo di pagine (analisi)	2	2000
Adjustable	No	No
Dimensioni massime del file delle etichette	10 MB	10 MB
Adjustable	No	No
Dimensioni massime della risposta JSON del riconoscimento ottico dei caratteri (OCR)	500 MB	500 MB
Adjustable	No	No
Numero massimo di modelli Template	500	5000
Adjustable	No	No
Numero massimo di modelli neurali	100	500
Adjustable	No	No

Uso del modello personalizzato

- ✓ [Modello di template personalizzato](#)
- ✓ [Modello neurale personalizzato](#)
- ✓ [Modelli di classificazione composti](#)
- ✓ [Modelli composti personalizzati](#)

Quota	Gratuito (F0) ¹	Standard (S0)
Limiti al numero di modelli composti	5	500 (valore predefinito)
Adjustable	No	No
Dimensioni del set di dati di training *Neurale e generativo	1 GB ³	1 GB (valore predefinito)
Adjustable	No	No
Dimensioni del set di dati di addestramento * Modello	50 MB ⁴	50 MB (valore predefinito)
Adjustable	No	No
Numero massimo di pagine (training) * Modello	500	500 (valore predefinito)
Adjustable	No	No
Numero massimo di pagine (training) * Neurale e generativo	50,000	50.000 (valore predefinito)
Adjustable	No	No
Training del modello neurale personalizzato	10 ore al mese ⁵	nessun limite (pagamento in base all'ora), iniziare con 10 ore gratuite ogni mese
Adjustable	No	Sì ³
Numero massimo di pagine (training) * Classificatore	25,000	25.000 (valore predefinito)
Adjustable	No	No
Numero massimo di tipi di documento (classi) * Classificatore	1000	1000 (valore predefinito)
Adjustable	No	No
Dimensioni del set di dati di addestramento * Classificatore	1GB	2 GB (valore predefinito)
Adjustable	No	No
Numero minimo di esempi per classe * Classificatore	5	5 (valore predefinito)
Adjustable	No	No

¹ Per il piano tariffario **Gratuito (F0)**, vedere anche le quote mensili nella [pagina dei prezzi](#).

² Vedere [procedure consigliate](#) e [istruzioni per la modifica](#).

³ Il numero di training dei modelli neurali viene reimpostato a ogni mese di calendario. Aprire una richiesta di supporto per aumentare il limite di training mensile. A partire dall'API v4.0, le richieste di training oltre 20 richieste in un mese di calendario vengono fatturate al livello di training. Per informazioni dettagliate, vedere i [prezzi](#).

⁴ Questo limite si applica a tutti i documenti presenti nella cartella del set di dati di training prima di eventuali aggiornamenti correlati all'etichettatura.

⁵ Questo limite si applica solo per `v 4.0 (2024-11-30 GA)` modelli neurali personalizzati. A partire da `v 4.0`, è supportato il training di documenti più grandi per durate più lunghe (fino a 10 ore gratuitamente e successivamente con addebito). Per altre informazioni, vedere la [pagina](#) del modello neurale personalizzato.

Descrizione dettagliata, modifica delle quote e procedure consigliate

I limiti predefiniti possono essere estesi richiedendo un aumento tramite un ticket di supporto. Prima di richiedere un aumento della quota (se applicabile), assicurarsi che sia necessario.

Se l'applicazione restituisce il codice di risposta 429 (*troppe richieste*) si supera la soglia per una o più transazioni al secondo (TPS):

- **Limite delle transazioni per secondo** Il TPS per l'invio delle richieste di analisi (POST)
- **Limite delle operazioni GET al secondo** Il TPS per l'interrogazione dei risultati delle operazioni di analisi (GET).
- **Le operazioni di gestione dei modelli al secondo limitano** le operazioni correlate alla gestione dei modelli, ad esempio compilazione/training e copia.
- **Le operazioni elenco al secondo limitano** le operazioni correlate all'elenco di modelli, operazioni.

Procedure consigliate generali per mitigare la limitazione

Per ridurre al minimo i problemi relativi alla limitazione delle richieste (codice di risposta 429), è consigliabile usare le tecniche seguenti:

- Implementare la logica di ripetizione dei tentativi nell'applicazione
- Evitare modifiche brusche nel carico di lavoro. Aumentare gradualmente il carico di lavoro
Example. L'applicazione utilizza Intelligenza Documentale e il carico di lavoro attuale è di 10 TPS (transazioni al secondo). Il secondo successivo si aumenta il carico a 40 TPS. Il risultato è

un codice di risposta 429 per alcune richieste quando si supera il limite di 15 TPS per l'invio di operazioni di analisi. È possibile eseguire il back-off dell'elaborazione per rimanere sotto i 15 TPS o richiedere un aumento del TPS per supportare i volumi più elevati.

Le sezioni successive descrivono casi specifici di modifica delle quote. Passare a [Informazioni sui documenti: aumento del limite di richieste simultanee](#)

Aumento del limite di richieste di transazioni al secondo

Per impostazione predefinita, il numero di transazioni al secondo è limitato a 15 transazioni per una risorsa di Informazioni sui documenti. Per il piano tariffario Standard, è possibile inviare richieste di aumento TPS, ma se possono essere approvate e a quale livello TPS dipenderà dai modelli di utilizzo giornaliero e dalle procedure consigliate seguite. Prima di inviare la richiesta, assicurarsi di avere familiarità con il materiale descritto in [questa sezione](#) e di conoscere queste [procedure consigliate](#).

L'aumento del limite di richieste simultanee **non** influisce direttamente sui costi. Il servizio Informazioni sui documenti usa il modello con pagamento in base all'utilizzo. Il limite definisce il livello di scalabilità del servizio prima che inizi la limitazione delle richieste.

Il valore esistente di diverse categorie di limiti delle richieste è disponibile tramite portale di Azure, nella scheda monitoraggio del pannello panoramica delle risorse.

Creare e inviare una richiesta di supporto per l'aumento di TPS

Per avviare l'aumento del limite di transazioni al secondo (TPS) per la risorsa, inviare la richiesta di supporto:

- Accedere al [portale di Azure](#) 
- Selezionare la risorsa di Informazioni sui documenti per cui si vuole aumentare il limite TPS
- Selezionare -Nuova richiesta di supporto- (gruppo Supporto e risoluzione dei problemi). Viene visualizzata una nuova finestra con informazioni popolate automaticamente sulla sottoscrizione e sulla risorsa di Azure.
- Immettere un -Riepilogo-, ad esempio "Aumentare il limite TPS di Informazioni sui documenti"
- Selezionare "Convalida quota o utilizzo" per il campo del tipo di problema.
- Selezionare -Avanti: Soluzioni-.
- Procedere con la creazione della richiesta
- Nella scheda Dettagli, immettere le informazioni seguenti nel campo -Descrizione-:
 - Nota che la richiesta riguarda la quota di Intelligenza Documentale.
 - Specificare un valore previsto di TPS che si vuole ottenere con la scalabilità. Anche se gli aumenti tps sono gratuiti, è consigliabile richiedere solo un TPS ragionevole per il carico

di lavoro.

- Informazioni sulle risorse di Azure
- Completare l'immissione delle informazioni necessarie e selezionare il pulsante -Crea- nella scheda -Rivedi e crea-
- Prendere nota del numero della richiesta di supporto nelle notifiche del portale di Azure. Attendere il supporto che ti contatterà presto per ulteriori dettagli.

Esempio di procedura consigliata per un modello di carico di lavoro

Questo esempio presenta l'approccio consigliato per ridurre la possibile limitazione delle richieste. Non si tratta di una *ricetta esatta*, ma semplicemente di un modello che si invita a seguire e a modificare in base alle esigenze.

Si supponga che per una risorsa di Informazioni sui documenti sia impostato il limite predefinito. Avviare il carico di lavoro per inviare le richieste di analisi. Se si rileva che viene visualizzata una limitazione frequente con il codice di risposta 429 quando si verifica il completamento, iniziare implementando un backoff esponenziale nella richiesta di risposta di analisi GET. Usando un tempo di attesa progressivamente più lungo tra i tentativi per risposte di errore consecutive, ad esempio un modello 2-5-13-34 per i ritardi tra le richieste. In generale, è consigliabile non chiamare la risposta get analyze più di una volta ogni 2 secondi per una richiesta POST corrispondente. La `analyze` risposta contiene anche un'intestazione **retry-after** che indica per quanto tempo è necessario attendere in secondi prima di verificare il completamento della richiesta.

Se si rileva una limitazione del numero di richieste POST per i documenti inviati, provare ad aggiungere un ritardo tra le richieste. Se il carico di lavoro richiede un livello superiore di elaborazione simultanea, è necessario creare una richiesta di supporto per aumentare i limiti di servizio per il numero di transazioni al secondo.

In genere, è consigliabile testare il carico di lavoro e i modelli di carico di lavoro prima di passare all'ambiente di produzione.

Passaggi successivi

Informazioni sui codici errore e sulla risoluzione dei problemi